PRÁCTICA OBLIGATORIA EVALUABLE

ESTADIFICACIÓN DEL CÁNCER

Objetivo

El objetivo es poner en práctica diferentes conceptos aprendidos durante el curso relacionados con la Minería de Texto y Procesamiento del Lenguaje Natural a través de un caso de estudio real.

Normativa de entrega

La entrega de esta práctica es ***obligatoria*** y puede realizarse ***individualmente o por parejas***. A continuación, se detallan otros datos de interés relacionados con la normativa de entrega:

- La fecha límite de entrega de la práctica será el día ***20 de mayo de 2026, a las 23:59h***.
- La entrega de la práctica se hará a través del formulario habilitado para ello en aula virtual.
- Se deberá enviar un único archivo comprimido con todo el código fuente que se haya implementado (ficheros .py o notebooks), junto con los *requirements* de ejecución necesarios para ejecutar la práctica (versiones de las librerías utilizadas, versión de Python empleada, ...).
- **Además**, en el mismo fichero comprimido se deberá adjuntar una memoria explicando lo que se ha hecho.
- **Importante**. Mediante esta práctica se va a simular un reto de investigación, de forma, que la práctica se compone de varias fases:
    - Fase de desarrollo: esta fase comienza el 26 de marzo de 2026, que es cuando se presenta el enunciado de la práctica y se libera el corpus con el que trabajar.
    - Fase de evaluación: fase que comienza el 16 de abril de 2026 y finaliza el 20 de mayo, coincidiendo con la fecha de entrega de la práctica.
- **Inscripción.** Se habilitará un formulario de inscripción de equipos participantes para la práctica. Dado que la práctica es obligatoria, todos los estudiantes de la asignatura deben de estar inscritos en el formulario, o bien de forma individual si deciden hacer la práctica individualmente, o bien en equipo si hacen la práctica por parejas. Tanto si se participa de forma individual, como si se participa en equipo, hay que inscribirse con un nombre de equipo, el cuál se utilizará en la fase de evaluación para mostrar el ranking.
    - <u>El periodo de inscripción de los equipos estará abierto desde el 26 de marzo de 2026 hasta el 12 de abril de 2026</u>.

Enunciado

La estadificación del cáncer se utiliza principalmente para iniciar un tratamiento eficaz. Sobre esta base, los médicos pueden averiguar cómo de grave es la condición del paciente y cómo de buenas son sus posibilidades de recuperación y supervivencia. Esto facilita la selección de métodos de tratamiento apropiados. Un sistema uniforme para evaluar el avance del cáncer también afecta a la realización de investigaciones para determinar la eficacia de las terapias y medicamentos indicados.

La clasificación TNM permite **evaluar el estadio del cáncer.** Cada una de las letras del nombre hace referencia a las características que se tienen en cuenta para determinar el grado de desarrollo de la enfermedad:

- T (tamaño y extensión del tumor primario)
- N (diseminación a los ganglios linfáticos cercanos)
- M (presencia de metástasis a distancia).

Una estadificación TNM precisa desempeña un papel crucial a la hora de determinar el pronóstico y orientar las decisiones terapéuticas.

A continuación, se describe con más detalle el significado de cada letra:

- T: indica el tamaño del tumor primario (principal). Su crecimiento y relación con los tejidos circundantes se clasifican en una escala de 0 a 4, siendo 4 la etapa más avanzada del cáncer.
    - TX: indica que no se puede detectar el tumor primario.
    - T0: indica que no se ha encontrado tumor primario.
    - T1 a T4: determina el tamaño y/o la extensión del tumor primario. A veces pueden aparecer letras junto a los números, por ejemplo, T4a o T4b (esto permite especificar más datos).

- N: describe el grado de propagación de la enfermedad a los ganglios linfáticos regionales. Aquí se usa una escala de 0 a 3, con algunos tumores de 0 a 2 o a 1.
    - NX: indica que no se pueden evaluar los ganglios linfáticos regionales.
    - N0: indica que no se encontró afectación de los ganglios linfáticos regionales.
    - N1 a N3: determina el número y la ubicación de los ganglios linfáticos regionales con células cancerosas.

- M: se refiere a la presencia o ausencia de metástasis a distancia. Aquí se utiliza una escala de 0 a 1.
    - MX: no se pueden evaluar las metástasis a distancia.
    - M0: no se encontraron metástasis a distancia.
    - De M1 a M2: se encontraron metástasis a distancia.

Al describir la enfermedad en base a este estándar de clasificación internacional cada letra llevará asociado un número al lado que en su conjunto está dando información detallada de la enfermedad. Por ejemplo, T1N0M0.

Los informes patológicos de *The Cancer Genome Atlas (TCGA)* contienen descripciones textuales detalladas y no estructuradas de las características de los tumores. La extracción y predicción automáticas de los componentes del estadio TNM a partir de estos informes pueden contribuir a la investigación sobre el cáncer a gran escala y ayudar a estandarizar los datos clínicos.

El **objetivo** de esta práctica es desarrollar un sistema que sea capaz de predecir el estadio T del cáncer del paciente a partir de un informe patológico del TCGA. Es decir, tiene que predecir el tamaño del tumor primario con alguna de las etiquetas T1, T2, T3 o T4.

Corpus

Se trabajará con una colección de informes patológicos, escritos en inglés, de pacientes del TCGA. Los informes patológicos y los metadatos clínicos TNM asociados provienen del portal de datos TCGA Genomic Data Commons (GDC) y son un subconjunto de un corpus creado con fines de investigación (Kefeli et al., 2024).

En total, el corpus que se proporciona para la fase de desarrollo se compone de 5158 informes patológicos. Se proporciona en formato CSV con tres columnas: patient_id, text y t. En la Figura 1 se presenta un fragmento del corpus.

```
patient_id,text,t
TCGA-BP-5195,"Date of Recelpt: Clinical Diagnosis & History: Incidental 3 cm left upper pole renal mass. Specimens Submitted: 1: Kidney, Left Upper Pole; Pa
carcinoma - Conventional (clear cell) type. Fuhrman Nuclear Grade: Nuclear grade II/IV. Tumor Size: Greatest diameter is 2.4 cm. Local Invasion (for renal c
Non-Neoplastic Kidney: shows focal chronic inflammation and focal superficial glomerulosclerosis. Adrenal Gland: Not identified. Lymph Nodes: Not identifie
kidney. JATTEST THAT THE ABOVE DIAGNOSIS IS BASED UPON MY PERSONAL EXAMINATION OF THE SLIDES (AND/OR OTHER MATERIAL), AND THAT IHAVE. REVIEWED AND APPROVED
""left upper pole renal tumor stitch marks deep margin"". It consists of a 6.6 X 3.7 x 2.9 cm wedge shaped portion of kidney with a suture marking the deep
11.6 x 8.4 x 4.6 cm aggregate of unremarkable. fibroadipose tissue. The margin is inked black and the specimen is serially sectioned to reveal a well-circum
confined to the renal parenchyma, no. extension into perirenal fat is identified. The clearance from the resection margin is 1.1 cm. A representative sectio
Is taken. Portions of the. tumor are submitted for TPS. Summary of sections: FSC - frozen section control. T tumor. M margin. RS - representative sections.
1. 2. m. 2. 1. rs. 1. 2. t. 2. Intraoperative Consultation: Note: The diagnoses given in this section pertain only to the. tissue sample examined at the tim
CORTICAL NEOPLASM. WITH BENIGN MARGIN. PERMANENT DIAGNOSIS: SAME.",T1
TCGA-D7-8573,"Material: 1) Material: stomach, Method of collection: Lesion resection. Histopathological diagnosis: (including test No. G-3155/12): Adenocarc
Lauren. Intestinal type Lauren. Macroscopic description: Adenocarcinoma tubuläre G3. Cancerous proliferation reaches the periteneal surface of the stomach.
inflammation with focal intestinal metaplasia. Adjacent part of the omentum free of cancerous lesions. 3 - (lesser curvature): Lymphonodulitis reactivaNo V
IV. Microscopic description: The specimen containing the stomach, after being incised along the greater curvature sized 18.5 X 16cm with the. omentum sized
proximal end: 8.0cm, from distal end: 5.0cm.",T3
TCGA-EI-7004,"page 1 / 1. copy No. 3. Examination: Histopathological examination. Cost of diagnostic procedure. Material: 1. Total organ resection - rectum
rectosigmoid junction. Macroscopic description: A 26 cm length of the large intestine with a piece of mesentery and periintestinal tissue sized 20 X 11.7 cm
mesentery infiltrating. the whole thickness of the intestine. The lesion surrounds 100% of the intestine circumference and narrows its. lumen, is located 1
Neighbouring lymph nodes are metastatic in gross appearance forming concretions. Microscopic description: Adenocarcinoma mucocellulare et mucinosum (G3). In
rectalis) et telae adiposae mesenterii et. mesorecti. Intestine ends clear of neoplastic lesions. Metastases carcinomatosae in lymphonodis (NO XXX/XXX). In
difficult to assess due to the concretions. Histopathology diagnosis: Adenocarcinoma mucocellulare et mucinosum flexure sigmoideo - rectalis. Mucocellular a
metastases in the lymph nodes (No XXX/XXX). (G3, Dukes C, Atler - Coller C2, pT4, pN2b).",T4
```

Figura 1. Fragmento del corpus proporcionado para la fase de desarrollo.

Métricas de evaluación

Se empleará la métrica *macro f1* para medir la calidad predictiva de las técnicas y modelos de clasificación desarrollados. Esta métrica calcula la media aritmética de los valores *f1* de las clases T1, T2, T3 y T4 analizadas, otorgándoles la misma relevancia en la clasificación. La siguiente ecuación muestra matemáticamente cómo calcular el valor *macro f1*, donde *n* es el número de clases analizadas (en este caso, cuatro):

$$\text{Macro-F1} = \frac{1}{n}\sum_{i=1}^{n} \text{F1}_i$$

Como recordatorio, el valor de *f1* de cada clase se obtiene haciendo una media armónica entre sus valores de *precision* y *recall*. En particular, el valor de *f1* es calculado por medio de las siguientes ecuaciones:

$$\text{Precision}_i = \frac{\text{TP}_i}{\text{TP}_i+\text{FP}_i} \qquad \text{Recall}_i = \frac{\text{TP}_i}{\text{TP}_i+\text{FN}_i} \qquad \text{F1}_i = 2 \times \frac{\text{Precision}_i \times \text{Recall}_i}{\text{Precision}_i+\text{Recall}_i}$$

Donde TP son los verdaderos positivos (*True Positive),* TN los verdaderos negativos (*True Negatives),* FP los falsos positivos (*False Positives)* y, por último, FN los falsos negativos (*False Negatives)*.

Dinámica de trabajo por fases

Como ya se ha indicado, existen dos fases diferenciadas para la realización de la práctica:

- Fase de desarrollo. Al comienzo de esta se libera el corpus con el que se trabajará y durante esta fase los equipos realizarán diferentes propuestas que irán evaluando. En la memoria final deberá de estar explicado todo el trabajo realizado hasta llegar al sistema que se considerará definitivo (el mejor sistema a juicio de cada participante). Es decir, para cada propuesta habrá que justificar qué se prueba, por qué, los resultados que da, un análisis de estos, etc.
- Fase de evaluación. Al comienzo de esta fase se libera un corpus de evaluación, sin anotaciones, que servirá como corpus de test. En unas fechas preestablecidas que se irán informando más adelante, se deberán subir los resultados del sistema que tenga cada equipo en ese momento. El formato se indicará más adelante. Así, cada semana se podrá publicar un ranking de los resultados que se van obteniendo por todos los equipos.

Durante la fase de evaluación, los equipos podrán seguir trabajando en sus propuestas y cada semana subir unos nuevos resultados.

Cuando termina la fase de evaluación y se entrega la práctica, las profesoras ejecutarán los códigos entregados, no solo sobre el conjunto de evaluación con el que se hace el ranking semanal, sino también sobre un nuevo conjunto de test.

Referencias

Kefeli, J., Berkowitz, J., Acitores Cortina, J.M., Tsang, K.K., y Tatonetti, N.P. (2024). Generalizable and automated classification of TNM stage from pathology reports with external validation. *Nature communications*, *15*(1), 8916. https://doi.org/10.1038/s41467-024-53190-9.

Requisitos mínimos que hay que cumplir

Para la realización de la práctica se podrán utilizar libremente todas las librerías vistas en clase. Por otra parte, **es importante no aplicar un único enfoque** para resolver el problema. Se requiere desarrollar varias propuestas y analizar los resultados de cada una indicando cuál puede ser más apropiada.

De este modo, es crucial no limitar la memoria únicamente al modelo que obtenga la mejor clasificación, sino evaluar y comparar el rendimiento de las diversas técnicas y enfoques abordados en la asignatura. Esto incluye, entre otros aspectos:

- Aplicación de diversos preprocesamientos textuales (como lematización, filtrado por categoría gramatical, …).
- Representación a través de vectorizaciones basadas en bolsas de palabras (como pesado binario, TF-IDF, …).
- Empleo de embeddings estáticos (como Word2Vec, Gensim, FastText, ...)
- Empleo de embeddings contextuales (como BERT, ELMO, ...)
- Utilización de modelos "clásicos" de aprendizaje automático (como Naive Bayes, Regresión Logística, SVM, …)
- Utilización de modelos de aprendizaje profundo (como CNNs, RNNs, LSTMs, fine-tuning de modelos pre-entrenados, ...)

El objetivo no es tanto lograr los mejores resultados en cuanto a las métricas de evaluación, sino que todo el trabajo que se hace esté bien justificado, explicado, sea coherente y se sepan analizar los resultados y saber redirigir las propuestas en base al trabajo anterior.

Requisitos mínimos para la memoria escrita

Esta sección del enunciado pretende aportar algunas directrices para la redacción de la memoria:

1) La memoria debe escribirse en español, con un mínimo de 15 páginas sin contar la portada y el índice.

2) Debe tener un formato estructurado con secciones y subsecciones.

3) Las imágenes no deberían de ser mayores de un tercio de una página.

4) El esqueleto debe seguir una estructura aproximada a:

    1. Portada

    2. Índice

    3. Introducción

    4. Propuestas explicadas con sus experimentos, resultados y análisis de estos

    5. Conclusiones